PENERAPAN RETRIEVAL AUGMENTED GENERATION DALAM ASISTEN DIGITAL UNTUK ANALISIS PERUBAHAN PERATURAN

LAPORAN TUGAS AKHIR

Oleh:

Kumara Daffa Prasetya

105220038

FAKULTAS SAINS DAN ILMU KOMPUTER

PROGRAM STUDI ILMU KOMPUTER

UNIVERSITAS PERTAMINA

AGUSTUS 2045

PENERAPAN RETRIEVAL AUGMENTED GENERATION DALAM ASISTEN DIGITAL UNTUK ANALISIS PERUBAHAN PERATURAN

LAPORAN TUGAS AKHIR

Oleh:

Kumara Daffa Prasetya

105220038

FAKULTAS SAINS DAN ILMU KOMPUTER

PROGRAM STUDI ILMU KOMPUTER

UNIVERSITAS PERTAMINA

AGUSTUS 2045

Universitas
Pertamina

LEMBAR PENGESAHAN

Judul Tugas Akhir	:	PENERAPAN RETRIEVAL AUGMENTED GENERATION DALAM ASISTEN DIGITAL UNTUK ANALISIS PERUBAHAN PERATURAN
Nama Mahasiswa	:	Kumara Daffa Prasetya
Nomor Induk Mahasiswa	:	105220038
Program Studi	:	Ilmu Komputer
Fakultas	:	Sains dan Ilmu Komputer
Tanggal Lulus Sidang Tugas Akhir	:	17 Agustus 2045

Jakarta, 17 Agustus 2045

MENGESAHKAN

Pembimbing

Ade Irawan

NIP.116xxx

MENGETAHUI,

Ketua Program Studi

Ade Irawan

NIP. 116xxx

LEMBAR PERNYATAAN

Dengan ini saya menyatakan bahwa Tugas Akhir berjudul PENERAPAN RETRIEVAL AUGMENTED GENERATION DALAM ASISTEN DIGITAL UNTUK ANALISIS PERUBAHAN PERATURAN ini adalah benar-benar merupakan hasil karya saya sendiri dan tidak mengandung materi yang ditulis oleh orang lain kecuali telah dikutip sebagai referensi yang sumbernya telah dituliskan secara jelas sesuai dengan kaidah penulisan karya ilmiah.

Apabila dikemudian hari ditemukan adanya kecurangan dalam karya ini, saya bersedia menerima sanksi dari Universitas Pertamina sesuai dengan peraturan yang berlaku.

Demi pengembangan ilmu pengetahuan, saya menyetujui untuk memberikan kepada Universitas Pertamina hak bebas royalti noneksklusif (*non-exclusive royalty-free right*) atas Tugas Akhir ini beserta perangkat yang ada. Dengan hak bebas royalti noneksklusif ini Universitas Pertamina berhak menyimpan, mengalih media/format-kan, mengelola dalam bentuk pangkatan data (*database*), merawat, dan mempublikasikan Tugas Akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Demikian pernyataan ini saya buat dengan sebenarnya.

Jakarta, 17 Agustus 2045

– Materai –

Yang membuat pernyataan,

Kumara Daffa Prasetya

ABSTRAK

Kumara Daffa Prasetya. **105220038**. PENERAPAN RETRIEVAL AUGMENTED GENERATION DALAM ASISTEN DIGITAL UNTUK ANALISIS PERUBAHAN PERATURAN.

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Donec odio elit, dictum in, hendrerit sit amet, egestas sed, leo. Praesent feugiat sapien aliquet odio. Integer vitae justo. Aliquam vestibulum fringilla lorem. Sed neque lectus, consectetuer at, consectetuer sed, eleifend ac, lectus. Nulla facilisi. Pellentesque eget lectus. Proin eu metus. Sed porttitor. In hac habitasse platea dictumst. Suspendisse eu lectus. Ut mi mi, lacinia sit amet, placerat et, mollis vitae, dui. Sed ante tellus, tristique ut, iaculis eu, malesuada ac, dui. Mauris nibh leo, facilisis non, adipiscing quis, ultrices a, dui.

Morbi luctus, wisi viverra faucibus pretium, nibh est placerat odio, nec commodo wisi enim eget quam. Quisque libero justo, consectetuer a, feugiat vitae, porttitor eu, libero. Suspendisse sed mauris vitae elit sollicitudin malesuada. Maecenas ultricies eros sit amet ante. Ut venenatis velit. Maecenas sed mi eget dui varius euismod. Phasellus aliquet volutpat odio. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Pellentesque sit amet pede ac sem eleifend consectetuer. Nullam elementum, urna vel imperdiet sodales, elit ipsum pharetra ligula, ac pretium ante justo a nulla. Curabitur tristique arcu eu metus. Vestibulum lectus. Proin mauris. Proin eu nunc eu urna hendrerit faucibus. Aliquam auctor, pede consequat laoreet varius, eros tellus scelerisque quam, pellentesque hendrerit ipsum dolor sed augue. Nulla nec lacus.

Kata kunci: pembelajaran mesin, komunikasi, jaringan, pemrosesan sinyal, energi

ABSTRACT

Kumara Daffa Prasetya. **105220038**. The Title of the Final Project.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

Keywords: machine learning, communication, network, signal processing, energy

KATA PENGANTAR

Terima kasih sudah menggunakan template Tugas Akhir ini. Telah habis waktu sekian lamanya untuk membuat dan memperbaiki template ini. Oleh karena itu, tolong jangan hilangkan kredit pembuat dan yang memperkaya template ini, sebagai bentuk apresiasi kalian. Doakan saja semoga ini menjadi amal jariah kami semua. Aamiin.

Seperti yang sering tertulis di bagian Kata Pengantar, tidak ada gading yang tak retak, perbaikan dan saran dari pengguna template ini sangat diharapkan.

Jakarta, 17 Agustus 2025

Kumara Daffa Prasetya

DAFTAR ISI

KATA PENGANTAR . . . . . **iii**

DAFTAR ISI . . . . . **iv**

DAFTAR TABEL . . . . . **vi**

DAFTAR GAMBAR . . . . . **vii**

BAB I PENDAHULUAN **1**

1.1 Latar Belakang 1

1.2 Rumusan Masalah 2

1.3 Batasan Masalah 2

1.4 Tujuan Penelitian 3

1.5 Manfaat Penelitian 3

BAB II TINJAUAN PUSTAKA **5**

2.1 *Chatbot* 5

2.1.1 Klasifikasi dan perkembangan *Chatbot* 5

2.1.2 Komponen *Natural Language Processing (NLP)* 6

2.1.3 Large Language Models (LLM) 6

2.1.4 Retrieval-Augmented Generation (RAG) 6

2.1.5 Evaluasi Chatbot dan RAGAS 7

BAB III METODE PENELITIAN **9**

3.1 Desain Arsitektur Sistem 9

3.2 *Data Ingestion Pipeline* 10

3.3 *Retrieval Pipeline* 10

3.4 Evaluasi Model 11

BAB IV HASIL DAN PEMBAHASAN **13**

BAB V KESIMPULAN DAN SARAN **15**

5.1 Kesimpulan 15
5.2 Saran 15

DAFTAR PUSTAKA **17**

LAMPIRAN A Judul Lampiran 1 . . . . . **19**
A.1 Coding 19
A.2 Coba Masukkan Gambar 20

LAMPIRAN B Judul Lampiran 2 . . . . . **21**

DAFTAR TABEL

DAFTAR GAMBAR

Gambar 3.1 Arsitektur Unified RAG (Conventional vs Version Aware) 9

Gambar A.2.1 Arsitektur Blok ResNet 20

Universitas
Pertamina

BAB I
PENDAHULUAN

1.1 Latar Belakang

Seiring berjalan waktu kemajuan Natural Language Processing (NLP), konsep Retrieval-Augmented Generation (RAG) mulai banyak diaplikasikan untuk menjawab permasalahan akses dan interpretasi dokumen teks yang kompleks. Konsep ini pertama kali diperkenalkan oleh Lewis et al. (2023), yang menggabungkan metode retrieval berbasis pencarian semantik dengan generation menggunakan Large Language Model (LLM). Melalui gabungan tersebut hasil sistem RAG dapat memberikan jawaban yang bersumber langsung dari dokumen rujukan, sehingga bisa meningkatkan akurasi dan transparansi dalam jawaban.

Penerapan teknologi tersebut sangat relevan mengingat pengelolaan dokumen regulasi universitas merupakan hal penting dalam tata kelola akademik dan administratif. Dokumen seperti peraturan rektor, pedoman akademik maupun kebijakan fakultas bersifat dinamis dan terus ada perubahan seiring dengan perkembangan kebijakan pendidikan tinggi. Perubahan tersebut bisa berupa revisi parsial, pembaruan pasal tertentu saja atau penggatian keseluruhan dokumen. Namun, permasalahan sistem pencarian dokumen regulasi yang umum digunakan berbasis kata kunci (keyword-based retrieval), sehingga sering terjadi gagal membedakan versi dokumen masih berlaku dan tidak bisa menelusuri hubungan antarversi regulasi yang saling terkait. Hal ini menimbulkan kesulitan bagi civitas akademik dalam memastikan validitas dan relevansi suatu kebijakan universitas.

Penelitian yang sudah ada menunjukan bahwa RAG memiliki kemampuan adaptif diberbagai ranah. Zhang et al. (2023) mengimplementasikan RAG pada bidang pendidikan (CHAX: A RAG-based Chatbot for Chax Education), sementara Amazou et al. (2025) menerapkannya dalam konteks hukum kontrak untuk meningkatkan akurasi dan kemampuan citation dalam sistem hukum digital.

Meskipun dari hasil penelitian yang sudah memberikan hasil yang menjanjikan, tetapi penelitian tersebut masih berfokus pada dokumen statis ayng tidak memiliki hubungan versi atau konteks temporal yang bisa berubah. Dalam konteks dokumen regulasi universitas, pendekatan RAG konvesional menghadapi masalah tambahan karena sifat dokumen yang amandatif (dapat berubah sebagian) dan temporal (memiliki periode berlaku). Kompleksitas ini memiliki permasalahan yang perlu diselesaikan dalam pengembangan asisten digital berbasis RAG untuk regulasi universitas, yaitu:

1. **Temporal Inconsistency**
   Sistem tidak dapat membedakan konteks waktu dari informasi, sehingga berpotensi memberikan jawaban berdasarkan dokumen yang sudah tidak berlaku.

2. **Partial Supersession**
   Perubahan regulasi diuniversitas sifat parsial, dimana hanya beberapa pasal atau ayat yang diperbarui. Sistem RAG tanpa mekanisme pelacakan versi cenderung mencampur versi lama dan baru.

3. **Citation Accuracy**
   Ketika sistem tidak memiliki manajemen versi dengan baik, refrensi terhadap sumber regulasi menjadi tidak akurat. Hal ini bisa menimbulkan resiko kesalahan interprentasi terhadap kebijakan yang berlaku.

4. **Structural Semantics Loss**
   Dokumen regulasi memiliki struktur yang kompleks jika proses *chunking* dan *embedding* tidak mempertimbangkan struktur sistem akan kehilangan konteks semantik antarbagian dan menurukan semantic retrieval.

1.2 Rumusan Masalah

Berdasarkan latar belakang permasalahan yang telah diuraikan, rumusan masalah dalam penelitian ini adalah:

1. Bagaimana menerapkan metode *chunking* dan *embedding* yang efektif untuk mempertahankan struktur hirarki dokumen regulasi (bab, pasal, ayat) agar konteks semantik tidak hilang saat proses *retrieval*?

2. Bagaimana mekanisme *retrieval* dan *generation* dapat dioptimalkan untuk memastikan akurasi sitasi, sehingga jawaban yang dihasilkan sistem merujuk secara tepat pada dokumen yang relevan?

3. Sejauh mana peningkatan kinerja sistem RAG dengan pendekatan *version-aware* dibandingkan RAG konvensional dalam aspek akurasi jawaban dan relevansi dokumen regulasi universitas?

1.3 Batasan Masalah

Agar penelitian ini lebih terarah dan fokus pada tujuan yang ingin dicapai, penulis menetapkan beberapa batasan masalah sebagai berikut:

1. **Lingkup Data**: Data yang digunakan dalam penelitian ini terbatas pada dokumen regulasi internal Universitas Pertamina (seperti Peraturan Rektor, SK, dan Pedoman Akademik) dalam format teks digital (PDF).

2. **Model Bahasa**: Penelitian ini menggunakan *Pre-trained Large Language Model* (LLM) sebagai generator jawaban (misalnya model berbasis GPT atau Llama) dan tidak melakukan proses *fine-tuning* atau pelatihan ulang pada model tersebut.

3. **Fokus Versioning**: Kemampuan *version-aware* pada sistem dibatasi pada identifikasi metadata dokumen (seperti tanggal berlaku dan nomor surat) untuk memfilter dokumen relevan, bukan melakukan analisis interpretasi hukum mendalam terhadap konflik antar pasal.

4. **Bahasa**: Sistem hanya dirancang untuk memproses dan menghasilkan jawaban dalam Bahasa Indonesia.

5. **Input Pengguna**: Pertanyaan yang diajukan pengguna diasumsikan berupa pertanyaan terkait kebijakan universitas, bukan pertanyaan yang bersifat opini atau prediksi masa depan.

1.4 Tujuan Penelitian

Tujuan utama dari penelitian ini adalah mengembangkan sistem pencarian informasi berbasis *Retrieval-Augmented Generation* (RAG) yang mampu menangani perubahan regulasi universitas. Secara spesifik, tujuan penelitian ini adalah:

1. Mengimplementasikan strategi *chunking* dan *embedding* yang mampu mempreservasi struktur hirarki dokumen (bab, pasal, ayat) untuk menjaga konteks semantik yang utuh.

2. Merancang mekanisme sitasi otomatis dalam proses *generation* untuk memastikan setiap jawaban yang diberikan memiliki rujukan ke dokumen regulasi yang digunakan.

3. Mengevaluasi performa sistem RAG yang dikembangkan menggunakan metrik relevansi dan akurasi (seperti *Precision*, *Recall*, atau *RAGAS score*) dibandingkan dengan pendekatan pencarian konvensional.

1.5 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. Membantu Sivitas Akademika Universitas Pertamina dalam mencari informasi regulasi secara akurat, khususnya dalam memastikan dokumen yang ditemukan adalah versi yang berlaku dan valid.

2. Meningkatkan efisiensi pencarian dokumen hukum universitas melalui teknologi *chatbot* berbasis *Retrieval-Augmented Generation* (RAG) yang mampu memahami konteks pertanyaan pengguna dengan lebih baik dibandingkan pencarian kata kunci biasa.

3. Menambah wawasan dan menjadi referensi bagi peneliti lain dalam pengembangan sistem tanya jawab otomatis (*chatbot*) berbasis teknologi *Retrieval-Augmented Generation* (RAG).

Universitas
Pertamina

BAB II
TINJAUAN PUSTAKA

2.1 *Chatbot*

Penggunaan *Chatbot* berkembang cukup pesat diberbagai bidang apapun dalam berapa tahun terakhir seperti pemasaran, sistem pendukung, pendidikan, perawatan kesehatan dan hiburan, Sementara *Chatbot* salah satu penerapan sistem AI(*Artifical Intelligence*) contoh paling dasar dari interaksi manusia-komputer(*Human-Computer Interaction*). Secara definisi, (*Chatbot*) adalah program komputer yang dirancang untuk mensimulasikan diskusi dengan pengguna manusia, terutama melalui internet. Dalam literatur, teknologi ini juga dikenal dengan sebutan seperti (*smart bots*), agen interaktif, asisten digital, atau entitas percakapan buatan (*artifical conversation entities*). Tujuan utama dari sistem ini tidak hanya semata untuk meniru percakapan manusia sehari-hari, tetapi juga bisa beguna untuk membantu kegiatan manusia dibidang lain.

2.1.1 Klasifikasi dan perkembangan *Chatbot*

Seiring dengan perkembangan, *chatbot* dapat diklasifikasikan berdasarkan metode pemprosesan input dan cara memberikan hasil respon. terdapat tiga model yang digunakan yaitu:

1. **Rule-based model**
   Ini merupakan arsitektur yang digunakan oleh sebagaian besar *chatbot* pada generasi awal. Pada sistem ini memilih respon berdasarkan kumpulan aturan yang ditetapkan dan mengenali bentuk kosakata dari teks input tanpa membuat jawaban baru. Pengetahuan pada *chatbot* ini buat secara manual *hand-coded*, sehingga model ini memiliki kelemahan seperti kesalahan ejaan atau tata bahasa dalam input pengguna.

2. **Retrieval-based model**
   Pada model ini memberikan fleksibilitas lebih karena dapat melakukan kueri dan menganalisis sumber dengan menggunakan *API*. *Chatbot* berbasis retrieval mengambil respons dari indeks yang ada sehingga pencocokan untuk memilih respon terbaik.

3. **Generative model**
   Model ini memberikan jawaban dengan cara lebih baik dari model sebelumnya dengan menggunakan algoritma *machine learning* dan *deep learning*. *Chatbot* jenis ini hampir mendekati manusia (*human-like*) karena mampu memberikan respon baru berdasarkan pesan pengguna saat ini dan sebelumnya.

2.1.2 Komponen *Natural Language Processing (NLP)*

Agar *chatbot* dapat berinteraksi secara efektif, sistem ini mengandalkan *NLP*. *NLP* adalah bidang kecerdasan buatan yang memanipulasi teks atau ucapan bahasa alami oleh komputer. Inti tugas *NLP* untuk *Natural Language Understanding (NLU)*, yang merupakan teknik mengimplementasikan respon kepada pengguna secara alami. *NLU* bertujuan untuk memproses konteks dan kata dari input bahasa alami pengguna yang mungkin tidak terstruktur, kemudian merespon sesuai dengan niat pengguna. Dalam proses ini, terdapat dua konsep penting:

I. Intent : Mewakili pemetaan antara apa yang dikatakan pengguna dan tindakan apa yang harus diambil oleh *chatbot*.

II. Entity : Merupakan nilai parameter spesifik dari input bahasa alami, seperti tanggal atau nama lokasi, untuk melengkapi pemahaman sistem terhadap permintaan pengguna.

2.1.3 Large Language Models (LLM)

Large Language Models (LLM) telah mendapatkan banyak perhatian dalam beberapa tahun terakhir dan diterapkan di berbagai industri Steininger, dkk. (2025). LLM didasarkan pada algoritma *deep learning* dan jaringan saraf tiruan (*artificial neural networks*) untuk memahami, menafsirkan, dan menghasilkan jawaban dalam bahasa manusia Steininger, dkk. (2025).

Proses pembuatan dan pelatihan LLM membutuhkan jumlah data yang sangat besar Steininger, dkk. (2025). Proses ini dimulai dengan fase *unsupervised learning* menggunakan data tidak terstruktur, dilanjutkan dengan *fine-tuning* menggunakan data terstruktur untuk konsep yang lebih spesifik, dan diakhiri dengan *reinforcement learning* Steininger, dkk. (2025).

Meskipun canggih, LLM memiliki kelemahan, yaitu sulitnya penyesuaian (*customization*) untuk topik spesifik karena kebutuhan data pelatihan yang besar Steininger, dkk. (2025). Selain itu, keterlacakan (*traceability*) jawaban juga menjadi masalah, di mana tidak selalu jelas bagaimana model mendapatkan jawabannya, yang dapat menyebabkan halusinasi atau informasi yang salah Steininger, dkk. (2025). Salah satu cara untuk mengatasi masalah ini adalah dengan menggunakan *Retrieval-Augmented Generation* (RAG) Steininger, dkk. (2025).

2.1.4 Retrieval-Augmented Generation (RAG)

Retrieval-Augmented Generation (RAG) pertama kali diperkenalkan oleh Lewis et al. (2020) sebagai modifikasi untuk LLM yang membatasi referensi data pada sekumpulan informasi tertentu, biasanya dari dokumen spesifik Steininger, dkk. (2025). Pendekatan ini memungkinkan penggunaan model untuk domain khusus.

RAG dibangun sebagai pendekatan dua langkah yang menggabungkan *retriever* (non-parametrik) dengan model *generator* (memori parametrik) Steininger, dkk. (2025).

1. **Retriever:** Terdiri dari *query encoder* yang mengubah pertanyaan pengguna menjadi representasi vektor, serta indeks dokumen. Indeks dokumen menggunakan matriks kesamaan (*similarity matrix*) untuk mengidentifikasi dan mengambil dokumen yang paling sesuai untuk menjawab pertanyaan Steininger, dkk. (2025).

2. **Generator:** Menggunakan dokumen yang diambil dari indeks beserta pertanyaan pengguna untuk membuat respons akhir Steininger, dkk. (2025). Dokumen yang diambil dapat dibatasi jumlahnya menggunakan pendekatan *top-k approximation*, di mana k adalah hiperparameter yang dapat disesuaikan Steininger, dkk. (2025).

2.1.5 Evaluasi Chatbot dan RAGAS

Mengevaluasi kualitas *pipeline* chatbot sangat penting untuk memastikan keberhasilan dan keakuratannya Steininger, dkk. (2025). Metode evaluasi tradisional seperti ROUGE dan BLEU, yang awalnya dikembangkan untuk penerjemahan mesin, mengandalkan *n-grams* untuk membandingkan teks yang dihasilkan dengan referensi Steininger, dkk. (2025).

Pendekatan yang lebih modern adalah menggunakan metode *LLM-as-a-judge*, di mana LLM digunakan untuk menilai output chatbot berdasarkan kriteria tertentu Steininger, dkk. (2025). Salah satu kerangka kerja yang menerapkan metodologi ini adalah RAGAS, yang menawarkan metrik yang kuat untuk mengevaluasi berbagai aspek kinerja RAG Steininger, dkk. (2025). Beberapa metrik utama dalam evaluasi ini meliputi:

- **Factual Correctness:** Mengevaluasi keakuratan faktual dari respons yang dihasilkan dengan membandingkannya dengan referensi dasar Steininger, dkk. (2025).
- **Context Precision:** Mengukur proporsi potongan (*chunks*) yang relevan di dalam konteks yang diambil (*retrieved context*) Steininger, dkk. (2025).
- **Context Recall:** Menilai kelengkapan pengambilan dokumen dengan mengukur seberapa banyak dokumen relevan yang berhasil diambil Steininger, dkk. (2025).
- **Faithfulness:** Mengevaluasi konsistensi faktual dari jawaban yang dihasilkan terhadap konteks yang diberikan, untuk memastikan jawaban tidak mengandung informasi yang tidak didukung (halusinasi) Steininger, dkk. (2025).
- **Answer Relevancy:** Memeriksa seberapa dekat jawaban yang dihasilkan menjawab pertanyaan awal (*prompt*) pengguna Steininger, dkk. (2025).

Universitas
Pertamina

BAB III

METODE PENELITIAN

Untuk menyelesaikan permasalahan yang dirumuskan, penelitian ini mengembangkan sistem *chatbot* dengan arsitektur *Unified RAG* yang mengintegrasikan metode konvensional dengan *version-aware*. Metodologi penelitian dirancang untuk menangani dokumen yang memiliki riwayat perubahan (versi) secara kronologis.

3.1 Desain Arsitektur Sistem

Sistem dibangun berdasarkan arsitektur yang memisahkan antara komponen standar RAG dengan komponen logika versi. Gambaran umum arsitektur sistem dapat dilihat pada Gambar 3.1.

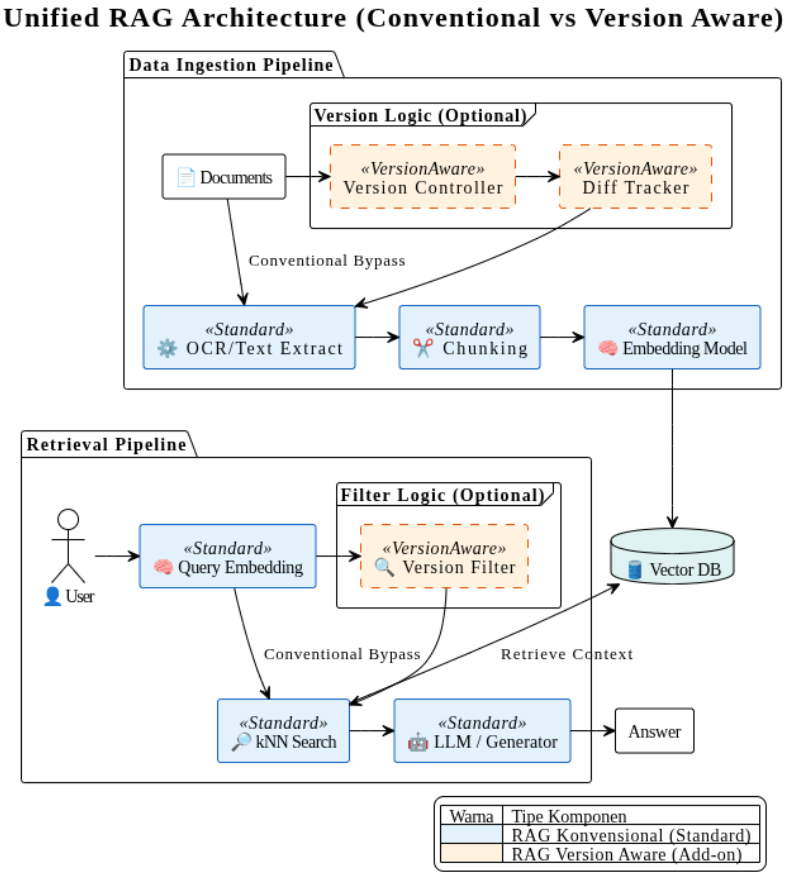

Gambar 3.1. Arsitektur Unified RAG (Conventional vs Version Aware)

Seperti yang ditunjukkan pada Gambar 3.1, arsitektur ini terdiri dari dua jalur utama (*pipeline*):

1. ***Data Ingestion Pipeline***: Bertanggung jawab untuk memproses dokumen mentah menjadi representasi vektor yang tersimpan dalam basis data.

2. ***Retrieval Pipeline***: Bertanggung jawab untuk menangani pertanyaan pengguna, melakukan pencarian relevansi, dan menghasilkan jawaban.

Komponen berwarna biru merepresentasikan proses RAG standar (*Standard Component*), sedangkan komponen berwarna oranye dengan garis putus-putus merepresentasikan logika tambahan (*Add-on Logic*) untuk menangani kapabilitas *version-aware*.

3.2 *Data Ingestion Pipeline*

Tahap ini digambarkan pada bagian atas Gambar 3.1. Proses ini bertujuan mengubah dokumen tidak terstruktur menjadi format yang dapat dipahami oleh mesin dengan menyertakan konteks versi.

1. ***Version Logic (Controller)***
   Sebelum dokumen diproses secara fisik, *Version Controller* mengidentifikasi metadata dokumen seperti Nomor Dokumen, Tag Versi (misalnya v1, v2), dan *Timestamp*. Pada implementasi kode, logika ini memastikan setiap dokumen yang masuk ditandai dengan ID unik dan waktu unggah untuk membedakan antara dokumen lama dan dokumen terbaru.

2. ***OCR/Text Extract***
   Dokumen PDF diproses menggunakan pustaka *pdfplumber* dengan mode *layout-aware* untuk mempertahankan struktur spasial teks. Jika dokumen berupa citra, sistem menggunakan *pytesseract* (OCR) untuk mengekstraksi karakter visual menjadi teks digital.

3. ***Chunking***
   Penelitian ini menerapkan metode *Line-Aware Chunking*. Berbeda dengan pemotongan karakter statis, metode ini membagi teks berdasarkan baris logis yang telah dibersihkan dari karakter sampah (*noise*). Setiap *chunk* kemudian diasosiasikan dengan metadata versi yang telah disiapkan sebelumnya.

4. ***Embedding Model***
   Teks yang telah terbagi dikonversi menjadi vektor numerik menggunakan model *intfloat/multilingual-e5-base*. Model ini dipilih karena kemampuannya yang optimal dalam menangani teks multibahasa.

5. ***Vector DB***
   Vektor dan metadata disimpan ke dalam *ChromaDB*. Basis data ini bertindak sebagai jembatan penyimpanan antara proses *ingestion* dan *retrieval*.

3.3 *Retrieval Pipeline*

Tahap ini digambarkan pada bagian bawah Gambar 3.1, yang menjelaskan bagaimana sistem merespons masukan pengguna.

1. ***Query Embedding***
   Pertanyaan pengguna dikonversi menjadi vektor menggunakan model yang sama dengan tahap *ingestion*.

2. ***Version Filter (VersionAware Logic)***
   Ini adalah komponen kunci yang membedakan penelitian ini dengan RAG konvensional. Sebelum atau sesudah pencarian vektor, sistem menerapkan filter logika:

   - Jika pengguna meminta **versi spesifik** (misal: "Gunakan v1"), sistem memfilter metadata `version='v1'`.
   - Jika pengguna meminta **versi terbaru** (*Latest*), sistem melakukan pemfilteran pasca-pencarian (*post-retrieval filtering*) untuk membandingkan *timestamp* antar dokumen yang memiliki ID sama, dan hanya mengambil dokumen dengan waktu terkini.

3. ***kNN Search***
   Sistem melakukan pencarian *k-Nearest Neighbors* (kNN) pada basis data vektor untuk menemukan potongan teks (*chunks*) yang paling mirip secara semantik dengan pertanyaan pengguna, yang telah lolos dari tahapan *Version Filter*.

4. ***LLM / Generator***
   Konteks yang relevan disusun menjadi *prompt* dan dikirim ke *Large Language Model* (Ollama/Llama3). Model diperintahkan untuk menjawab hanya berdasarkan konteks yang ditemukan.

3.4 Evaluasi Model

Untuk mengukur efektivitas arsitektur *Version-Aware* ini dibandingkan dengan RAG Konvensional, dilakukan evaluasi menggunakan metrik RAGAS (*Retrieval Augmented Generation Assessment*).

1. ***Context Precision***: Mengukur apakah sistem berhasil mengambil versi dokumen yang tepat (misal: tidak mengambil dokumen v1 saat diminta v2).

2. ***Faithfulness***: Mengukur seberapa akurat jawaban yang dihasilkan berdasarkan konteks versi yang diambil, tanpa halusinasi.

3. ***Answer Relevancy***: Mengukur relevansi jawaban terhadap pertanyaan pengguna.

Universitas
Pertamina

BAB IV

HASIL DAN PEMBAHASAN

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetuer.

Universitas
Pertamina

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetuer.

5.2 Saran

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Universitas
Pertamina

DAFTAR PUSTAKA

Steininger, S., Kezer, S., Rief, J., Spicker, E., Preis, S., dan Fottner, J. (2025). Chax: a rag-based chatbot for cax education. In *Proceedings of the Design Society*, volume 5. ICED25.

Universitas
Pertamina

LAMPIRAN A

Judul Lampiran 1

A.1 Coding

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetuer id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Cara *Web Scraping*

```

from bs4 import BeautifulSoup
import requests
from time import sleep
base_url = "https://www.oreilly.com/search/" + \
           "/?q=data&type=*&rows=10&page="


books = []
NUM_PAGES = 31

for page_num in range(1, NUM_PAGES + 1):
    print("souping page", page_num, ",", len(books), " found")
    url = base_url + str(page_num)
    soup = BeautifulSoup(requests.get(url).text, 'html5lib')

    for td in soup('td', 'thumbtext'): if not is_video(td):
        books.append(book_info(td))

    # give a break
    sleep(30)

def get_year(book):
    return int(book["date"].split()[1])
```

```
25
26  year_counts = Counter(get_year(book) for book in books
27                        if get_year(book) <= 2014)
28
29  import matplotlib.pyplot as plt
30  years = sorted(year_counts)
31  book_counts = [year_counts[year] for year in years]
32  plt.plot(years, book_counts)
33  plt.ylabel("# of data books")
34  plt.title("Data is Big!")
35  plt.show()
36
```

A.2 Coba Masukkan Gambar

Gambar A.2.1 sama dengan di Bab 2.

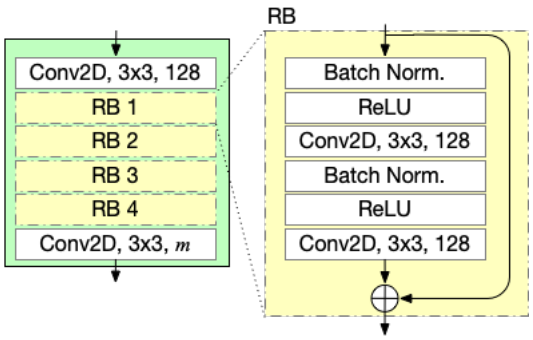

Gambar A.2.1. Arsitektur Blok ResNet

LAMPIRAN B

Judul Lampiran 2

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.